Image Generation from Contextually-Contradictory Prompts

arxiv

В этой статье приводится метод адаптации пайплайна генерации диффузионным моделькми под промпты, где до сих пор, как оказалось, эти модели плохо справлялись.

Все крутится вокруг понятия contextual contradiction. Так называют нетипичный для выученных приоров модели промпт. Он не содержит в себе ничего невозможного, но модель не может хорошо разумить латент x_t в картинку x_0, соответствующие промпту, поскольку плохо представляет себе описанное в промпте или не может одновременно хорошо учесть разные части промпта

Пример ошибки генерации приведен в Figure 1

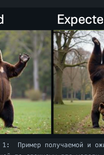

Figure 1: Пример получаемой и ожидаемой генерацией по сложным для модели промпту:
"A bear is performing a handstand in the park"

Авторы предложили метод генерации для разрешения таких непривятных ситуаций.

Метод генерации

Предлагаемый пайплайн разумения основывается на идеи о том, что латент на разных шагах денойза приобретает разные семантические признаки. Так на первых шагах появляются общие формы, большие объекты, цвета, фон, а на поздних — текстуры, мелкие объекты.

Идея авторов заключается в том, что мы можем в ручном режиме контролировать, что на каком этапе денойза должна вырисовать модель, чтобы в итоге мы получили то, что хотели, несмотря на то, что в лоб модель сама бы это не смогла нарисовать. Мы разобьем противоречивый промпт на несколько простых, которые, благодаря таймингам образования разных видов семантики, приведут семпл куда надо, не ставя перед моделью задачи изобразить то, что она не знает как.

Для этого, как видно из идея метода, нужно чтобы у того, кто бьет промпт на цепочку проху промптов, было комплексное представление о мире и умение работать с текстом. И это LLM. Далее авторы делают все эксперименты, используя gpt-4o.

Формализация метода

Дан промпт P, описывающий не типичную для модели картинку.

1. Как обычно семплим латент из $\mathcal{N}(0, I)$
2. По промпту P с помощью LLM строим цепочку "хороших" проху промптов $\{p_1, ..., p_n\}$ и тайместпов $\{t_1, ..., t_n\}$ на которых они будут сменять друг друга. Примечательно, что LLM должна сама определить сколько проху промптов должно быть. Так, если языковая модель противоречий в промпте не обнаружит, она вернет список из одного оригинального промпта без тайместпов, это отражено на Figure 3. Авторы предлагает генерировать проху промпты и таймстемпы, давая LLM системный промпт Figure 2, In-context примеры Figure 3 и непосредственно целевой промпт.
3. Обычное итеративное расшумление латента со сменой подготовленных проху промптов в данные таймстепы

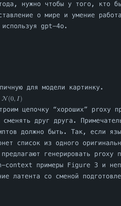

Figure 2: Системный промпт для LLM, генерирующей проху промпты.
Приводу пояснения, за что отвечает каждая часть.

Figure 3: Промпт с примерами для in-context learning.
Синим подчеркнуты примеры, как модель должна сравнеривать
на промпты где надо сделать проху промпты.
Красным — как ей быть, если оригинальный промпт не содержит противоречий.

Предложенный алгоритм так же визуализирован на Figure 4

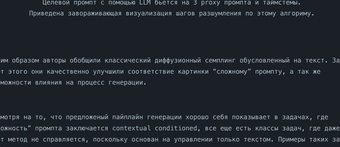

Figure 4: Схема работы алгоритма для "сложного" промпта: "A lion asi doing a handstand"
Целевой промпт с помощью LLM бьется на 3 проху промпта и таймстемпы.
Приведена завораживающая визуализация шагов разумения по этому алгоритму.

Таким образом авторы обобщили классический диффузионный семплинг обусловленный на текст. За счет этого они качественно улучшили соответствие картинки "сложному" промпту, а так же возможности влияния на процесс генерации.

Несмотря на то, что предложенный пайплайн генерации хорошо себя показывает в задачах, где "сложность" промпта заключается contextual conditioned, все еще есть классы задач, где даже этот метод не справляется, поскольку основан на управлении только текстом. Примеры таких задач на Figure 5

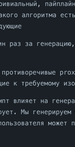

Figure 5: Генерации, где промпт требует
определенного геометрического расположения (ваза вверх ногами),
определенного числа объектов (6 пальцев),
точные направления (тень кошки смотрит в другую сторону)

Мои мысли насчет статьи

В статье ввели интересный, довольно тривиальный, пайплайн генерации, немного обидно, что сам не догадался до него. К сожалению у такого алгоритма есть недостатки и кроме неточностей, на которые указали авторы. Я заметил следующее

- Включение в пайплайн LLM, хоть и один раз за генерацию, должно заметно замедлить семплинг большого числа картинок
- LLM не идеальны и сами могут давать противоречивые проху промпты или в целом не "идеальные" цепочки проху промптов — не приводящие к требуемому изображению.
- Противоречивый пользовательский промпт влияет на генерацию уже только косвенно, тк LLM его дробит на проху промпты и перефразирует. Мы генерируем что-то похожее на промпт, но не по нему в точности. Таким образом для пользователя может потеряться возможность сгенерировать именно то, что он хотел.
- LLM по вшитым нравственным/идеологическим/... ограничениям может отказаться писать про то, что мы хотим нарисовать. Это непринятное нововведение от такого пайплайна.

Кажется что изначальная проблема в том, что диффузионка недостаточно сложная и обучается на недостаточно разнообразных данных, чтобы она могла обобщить "человек стоящий на руках" и хорошо сгенерировать "медведь стоящий на руках", а так же понять, что тень и кошка могут смотреть в разные стороны. Вообще это похоже на недостаточное представление о мире. Хорошо бы как-то диффузионкам преодолеть этот барьер, как его преодолели LLM в последние годы. К сожалению я недостаточно подробно разбираюсь в LLM, но насколько я понимаю, тут могу прям заблуждаться, базовые представления о мире у них появляются на претрейне. Надо бы как-то обобщить суть претрейна на диффузионки или, накидав идей, но не факт что хороших

- собрать франкенштейна из диффузионки и LLM
- как-то сдистилить знания из LLM в диффузионку

вообщем мысли мои в эту сторону, но мат аппарата в LLM мне для их развития не хватает.